

EDA e Regressione

disponibile su: <https://github.com/gianlucameni/regressione-lineare>

A cura di: Gianluca Meni e Samuele Ghezzi

Indice

- ☐ il dataset (spiegazione generale e target)
- ☐ struttura del progetto (packages e spiegazione breve)
- ☐ data cleaning: missing values e outliers
- ☐ correlazione
- ☐ PCA
- ☐ regressioni (varie tipologie)
- ☐ metriche
- ☐ risultati ottenuti (analisi metriche e osservazione sulla PCA)
- ☐ progetti futuri

Descrizione delle Variabili del Dataset


Questa tabella fornisce una panoramica dettagliata di ciascuna variabile presente nel dataset, inclusi il loro ruolo, tipo di dato, una breve descrizione, le unità di misura e la presenza di valori mancanti.

Variable Name	Role	Type	Description	Units	Missing Values
displacement	Feature	Continuous	Cilindrata del motore	cubici	no
mpg	Target	Continuous	Consumo di carburante	miglia per gallone	no
cylinders	Feature	Integer	Numero di cilindri	unità	no
horsepower	Feature	Continuous	Potenza del motore	cavalli vapore	yes
weight	Feature	Continuous	Peso del veicolo	libbre	no
acceleration	Feature	Continuous	Tempo di accelerazione 0-60 mph	secondi	no
model_year	Feature	Integer	Anno del modello del veicolo	anno	no
origin	Feature	Integer	Paese di origine (codificato)	codice numerico	no
car_name	ID	Categorical	Nome del modello dell'auto	testo	no

Struttura del progetto









Il progetto "regressione-lineare" è così strutturato:

- package it-valtellina che contiene:
 - analyzer: analyzer.py tool di analisi, manipolazione e visualizzazione dati
 - splitter_train_test: splitter_train_test.py per la suddivisione del dataframe in train e test set
 - regression_model: regression_model.py per eseguire le predizioni e ottenere le metriche dei diversi modelli di regressione disponibili
- main.py: connessione con Flask e dichiarazione delle route per l'utilizzo dei metodi
- test.py: preprocessing e test analisi del dataset
- requirements.txt: librerie necessarie
- Dockerfile: file di istruzioni per la creazione del container



Analisi della Distribuzione delle Feature

Per comprendere meglio il comportamento di ciascuna feature, è stata analizzata la loro distribuzione. Data la dimensione limitata del dataset, abbiamo applicato il **test di Shapiro-Wilk** per valutarne la normalità. I risultati hanno rivelato che **tutte** le feature presentano una **distribuzione non normale**.



Gestione Missing values

La feature **horsepower** presenta 6 valori mancanti su 398 record.

Per gestire questi missing, imputiamo la mediana perché la distribuzione è asimmetrica, sapendo che non ha distribuzione normale dall'analisi precedente, e con una skewness > 1.

La **skewness** indica l'asimmetria, misura quanto una distribuzione "è spostata rispetto a una distribuzione normale.

Gestione outliers


Feature	Outliers Count	Outliers Percentage
horsepower	10	2.76%
acceleration	7	1.76%
mpg	1	0.25%

Poiché i valori degli outliers sono comunque plausibili, vengono mantenuti nel dataset. Successivamente, durante la PCA, verrà applicato il **robust scaling** per mitigare l'impatto degli outliers sulla riduzione di dimensionalità.

```
{  
  "totale outliers": {  
    "acceleration": 7,  
    "cylinders": 0,  
    "displacement": 0,  
    "horsepower": 10,  
    "model_year": 0,  
    "mpg": 1,  
    "origin": 0,  
    "weight": 0  
  }  
}
```

Analisi della Correlazione Lineare

La correlazione lineare misura il grado di relazione lineare tra due variabili. Valori prossimi a 1 o -1 indicano una forte correlazione, mentre valori prossimi a 0 indicano assenza di correlazione lineare.



⚠ **Rischio di Multicollinearità:** Dalla matrice di correlazione emerge che le feature **displacement, cylinders, horsepower e weight** presentano correlazioni molto elevate tra loro. Questa multicollinearità può causare instabilità nei coefficienti del modello e rendere difficile l'interpretazione dell'importanza relativa delle variabili. Per mitigare questo problema, abbiamo applicato tecniche di regolarizzazione (Lasso e Ridge) e riduzione di dimensionalità (PCA).

Selezione delle Feature: Identificazione delle Colonne Non Essenziali

Per semplificare la nostra analisi e concentrarci sulle variabili con potere predittivo, abbiamo identificato e rimosso alcune colonne dal dataset.

car name

Questa colonna, che rappresenta l'identificatore univoco per ogni veicolo, è stata rimossa all'inizio del processo poiché non offre alcun valore predittivo per l'efficienza del carburante.

origin

La colonna 'origin', una feature categorica codificata, è stata anch'essa esclusa. Le sue informazioni sono state ritenute potenzialmente ridondanti o di valore limitato per il compito di regressione, senza contribuire significativamente alla performance del modello.

Principal Component Analysis (PCA)

La Principal Component Analysis (PCA) è una tecnica di riduzione di dimensionalità applicata al **training set** che trasforma un insieme di variabili correlate in un nuovo insieme di variabili non correlate, chiamate componenti principali. Questo approccio consente di semplificare il modello mantenendo la maggior parte della varianza nei dati.

Metodologia Applicata

Nel nostro progetto, abbiamo applicato il **robust scaling** per standardizzare i dati per la PCA. Questa scelta è stata cruciale perché il dataset contiene outliers (come identificato nell'analisi precedente). Il robust scaling utilizza la mediana e l'intervallo interquartile anziché la media e la deviazione standard, rendendolo meno sensibile agli outliers e garantendo una riduzione di dimensionalità più stabile e affidabile.

Risultati Ottenuti

Impostando la soglia di varianza spiegata al 95%, la PCA ha ridotto il dataset a sole 3 componenti principali, mantenendo il 95% della varianza originale. Questa riduzione significativa semplifica il modello senza perdere informazioni critiche.

PC1 (Potenza)

Rappresenta la potenza complessiva del veicolo, unendo horsepower, displacement, cylinders e weight in un'unica dimensione.

PC2 (Accelerazione)

Cattura la capacità di accelerazione del veicolo.

PC3 (Anno)

Rappresenta l'anno del modello del veicolo.

Modelli di Regressione

Diversi approcci di regressione utilizzati per modellare efficacemente le relazioni tra le variabili e migliorare la previsione.

Regressione Lineare

Un metodo fondamentale che stabilisce una relazione lineare tra la variabile dipendente e una o più variabili indipendenti, minimizzando la somma dei quadrati degli errori.

Lasso Regression

Aggiunge un termine di penalità che riduce la dimensione dei coefficienti e può portare alcuni di essi esattamente a zero, utile per la selezione delle feature e la prevenzione dell'overfitting.

Ridge Regression

Applica una penalità che riduce i coefficienti verso lo zero senza annullarli del tutto, risultando efficace per gestire la multicollinearità.

Metriche di Valutazione per la Regressione

Per valutare l'accuratezza e l'efficacia dei modelli di regressione, utilizziamo diverse metriche chiave che quantificano l'errore e la bontà dell'adattamento.

MSE (Mean Squared Error)

Calcola la media dei quadrati degli errori, penalizzando maggiormente le predizioni molto distanti dai valori reali.

RMSE (Root Mean Squared Error)

È la radice quadrata dell'MSE, fornendo una metrica nella stessa unità della variabile target e quindi più facilmente interpretabile.

MAE (Mean Absolute Error)

Calcola la media dei valori assoluti degli errori. È meno sensibile agli outlier rispetto all'MSE, offrendo una misura più robusta dell'errore medio.

R² (Coefficiente di Determinazione)

Indica la proporzione della varianza nella variabile dipendente che può essere spiegata dalle variabili indipendenti. Varia da 0 a 1, dove 1 indica una perfetta spiegazione.

Risultati Ottenuti

L'analisi comparativa dei modelli di regressione e l'impatto della riduzione di dimensionalità con PCA hanno rivelato intuizioni chiave sulla performance e l'interpretabilità.

Miglior Regressione: Lasso

La regressione Lasso si è distinta per la sua performance superiore. La capacità di selezione delle feature, azzerando i coefficienti delle variabili meno rilevanti, ha permesso di ottenere un modello robusto

PCA vs no PCA

L'applicazione della PCA (Principal Component Analysis) ha portato a risultati leggermente inferiori in termini di metriche dato il numero limitato di feature nel dataset

Response 200 OK POST 1336ms

JSON Body Headers

```
1 {
2   "metriche": {
3     "MAE": 2.583792474007512,
4     "MSE": 10.482361318486085,
5     "R2": 0.8050389687808563,
6     "RMSE": 3.237647497564564
7   }
8 }
```



Possibili Sviluppi Futuri

Per elevare ulteriormente le capacità predittive e l'usabilità del nostro progetto, proponiamo i seguenti miglioramenti e integrazioni:



Visualizzazione Grafici Avanzata

Aggiungere più endpoint per la visualizzazione dinamica di grafici che illustrano distribuzioni, correlazioni e performance dei modelli.



Controllo Veicolo Personalizzato

Implementare una funzionalità che consenta agli utenti di inserire i parametri di un veicolo per ottenere previsioni personalizzate sul consumo di carburante.



Validazione Dataset Accurata

Adottare tecniche più robuste come la Cross-Validation per una valutazione più affidabile della generalizzabilità del modello e prevenire l'overfitting.



Introduzione Elastic Net

Integrare il modello di regressione Elastic Net, che combina le penalità di Lasso e Ridge per gestire al meglio la selezione delle feature e la multicollinearità.

GRAZIE
PER L'ATTENZIONE